

# 最小二乗法

2022 年 4 月 29 日

## 目次

1	概要	1
2	線形回帰 (直線) の場合	2
3	一般的な多項式の場合	3
4	発展編	4
4.1	円の場合 . . . . .	4
4.2	球の場合 . . . . .	6
5	(応用) 疑似逆行列	8

## 1 概要

ある観測データの組  $(x, y)$  は、モデル関数  $f(x)$  と誤差  $\varepsilon$  の和で

$$y = f(x) + \varepsilon \quad (1)$$

と表せるとする。

$N$  組の観測データ  $(x_i, y_i)$  が与えられたとき、各  $x_i$  についてモデルから得られる予測値  $f(x_i)$  と、実際の測定値  $y_i$  の誤差  $\varepsilon_i$  つまり

$$\varepsilon_i := |f(x_i) - y_i| \quad (2)$$

の和を最小にすることを考えたい。しかし、絶対値があると後々の計算が大変なので、実際には、誤差の二乗和

$$\Delta := \frac{1}{2} \sum_{i=1}^N \varepsilon_i^2 = \frac{1}{2} \sum_{i=1}^N (f(x_i) - y_i)^2 \quad (3)$$

を最小にするようなモデル  $f(x)$  を求める。なお、係数  $\frac{1}{2}$  は、後の計算の時に、多少計算が楽になるのを見越して付けているだけで、本質ではない。

以下のセクションでは、簡単なものから複雑なものまで、具体的に求めてみる。

## 2 線形回帰 (直線) の場合

モデル関数は

$$f(x) = ax + b \quad (4)$$

であるから、式 (3) は

$$\Delta = \frac{1}{2} \sum_{i=1}^N \varepsilon_i^2 = \frac{1}{2} \sum_{i=1}^N (ax_i + b - y_i)^2 \quad (5)$$

となる。これを最小化する  $a, b$  を求めればよい。これを  $a, b$  に関する二次関数と見れば、この関数が最小値を取る点では  $a$  および  $b$  についての偏微分がゼロであるから、

$$\begin{aligned} \frac{\partial}{\partial a} \Delta &= 0, \\ \frac{\partial}{\partial b} \Delta &= 0 \end{aligned}$$

を連立して解けばよい。実際に計算してみると

$$\begin{aligned} \frac{\partial}{\partial a} \Delta &= \sum_{i=1}^N (ax_i + b - y_i) x_i = a \sum_{i=1}^N x_i^2 + b \sum_{i=1}^N x_i - \sum_{i=1}^N x_i y_i = 0, \\ \frac{\partial}{\partial b} \Delta &= \sum_{i=1}^N (ax_i + b - y_i) 1 = a \sum_{i=1}^N x_i + b \sum_{i=1}^N 1 - \sum_{i=1}^N y_i = 0, \end{aligned}$$

すなわち

$$\begin{cases} \left( \sum_{i=1}^N x_i^2 \right) a + \left( \sum_{i=1}^N x_i \right) b = \sum_{i=1}^N x_i y_i, \\ \left( \sum_{i=1}^N x_i \right) a + \left( \sum_{i=1}^N 1 \right) b = \sum_{i=1}^N y_i, \end{cases} \quad (6)$$

を解けばよい。行列を使って書けば

$$\begin{bmatrix} \sum_{i=1}^N x_i^2 & \sum_{i=1}^N x_i \\ \sum_{i=1}^N x_i & \sum_{i=1}^N 1 \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^N x_i y_i \\ \sum_{i=1}^N y_i \end{bmatrix} \quad (7)$$

よって、

$$Det := \left( \sum_{i=1}^N x_i^2 \right) \left( \sum_{i=1}^N 1 \right) - \left( \sum_{i=1}^N x_i \right)^2 \quad (8)$$

とおけば、

$$\begin{aligned} \begin{bmatrix} a \\ b \end{bmatrix} &= \begin{bmatrix} \sum_{i=1}^N x_i^2 & \sum_{i=1}^N x_i \\ \sum_{i=1}^N x_i & \sum_{i=1}^N 1 \end{bmatrix}^{-1} \begin{bmatrix} \sum_{i=1}^N x_i y_i \\ \sum_{i=1}^N y_i \end{bmatrix} \\ &= \frac{1}{Det} \begin{bmatrix} \sum_{i=1}^N 1 & -\sum_{i=1}^N x_i \\ -\sum_{i=1}^N x_i & \sum_{i=1}^N x_i^2 \end{bmatrix} \begin{bmatrix} \sum_{i=1}^N x_i y_i \\ \sum_{i=1}^N y_i \end{bmatrix} \end{aligned} \quad (9)$$

さらに  $\sum_{i=1}^N 1 = N$  であるから、最終的に

$$\begin{aligned} a &= \frac{N \sum_{i=1}^N x_i y_i - \left( \sum_{i=1}^N x_i \right) \left( \sum_{i=1}^N y_i \right)}{N \sum_{i=1}^N x_i^2 - \left( \sum_{i=1}^N x_i \right)^2}, \\ b &= \frac{\left( \sum_{i=1}^N x_i^2 \right) \left( \sum_{i=1}^N y_i \right) - \left( \sum_{i=1}^N x_i y_i \right) \left( \sum_{i=1}^N x_i \right)}{N \sum_{i=1}^N x_i^2 - \left( \sum_{i=1}^N x_i \right)^2}, \end{aligned} \quad (10)$$

### 3 一般的な多項式の場合

モデル関数は

$$f(x) = a_0 + a_1 x^1 + a_2 x_i^2 \cdots + a_{n-1} x^{n-1} + a_n x^n \quad (11)$$

であるから、式 (3) は

$$\Delta = \frac{1}{2} \sum_{i=1}^N (a_0 + a_1 x_i + a_2 x_i^2 + \cdots + a_{n-1} x_i^{n-1} + a_n x_i^n - y_i)^2 \quad (12)$$

となる。先ほどと同様に  $a_0, a_1, \dots, a_n$  で偏微分すると

$$\begin{aligned} \frac{\partial}{\partial a_0} \Delta &= \sum_{i=1}^N (a_0 + a_1 x_i + a_2 x_i^2 + \cdots + a_n x_i^n - y_i) \cdot 1, \\ \frac{\partial}{\partial a_1} \Delta &= \sum_{i=1}^N (a_0 + a_1 x_i + a_2 x_i^2 + \cdots + a_n x_i^n - y_i) x_i, \\ \frac{\partial}{\partial a_2} \Delta &= \sum_{i=1}^N (a_0 + a_1 x_i + a_2 x_i^2 + \cdots + a_n x_i^n - y_i) x_i^2, \\ &\vdots \\ \frac{\partial}{\partial a_n} \Delta &= \sum_{i=1}^N (a_0 + a_1 x_i + a_2 x_i^2 + \cdots + a_n x_i^n - y_i) x_i^n \end{aligned} \quad (13)$$

この各式がゼロとおいて、移項して行列の形に纏めると

$$\begin{bmatrix} \sum_{i=1}^N x_i^0, & \sum_{i=1}^N x_i^1, & \sum_{i=1}^N x_i^2, & \cdots, & \sum_{i=1}^N x_i^n \\ \sum_{i=1}^N x_i^1, & \sum_{i=1}^N x_i^2, & \sum_{i=1}^N x_i^3, & \cdots, & \sum_{i=1}^N x_i^{n+1} \\ \sum_{i=1}^N x_i^2, & \sum_{i=1}^N x_i^3, & \sum_{i=1}^N x_i^4, & \cdots, & \sum_{i=1}^N x_i^{n+2} \\ \vdots, & \vdots, & \vdots, & \ddots, & \vdots \\ \sum_{i=1}^N x_i^n, & \sum_{i=1}^N x_i^{n+1}, & \sum_{i=1}^N x_i^{n+2}, & \cdots, & \sum_{i=1}^N x_i^{2n} \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \\ \vdots \\ a_n \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^N x_i^0 y_i \\ \sum_{i=1}^N x_i^1 y_i \\ \sum_{i=1}^N x_i^2 y_i \\ \vdots \\ \sum_{i=1}^N x_i^n y_i \end{bmatrix} \quad (14)$$

後はこれに掃き出し法や LU 分解など、連立一次方程式の解法アルゴリズムを適用すれば良い。

## 4 発展編

### 4.1 円の場合

円の場合は  $y = f(x)$  の形で書けない (書けなくはないが面倒) ので工夫が必要である。中心  $(a, b)$  半径  $r$  の円の場合  $(x, y)$  は

$$(x - a)^2 + (y - b)^2 = r^2 \quad (15)$$

を満たす。

今までの方法では  $y = f(x)$  という形式だったが、これを変形すると点  $(x_i, y_i)$  がこのモデル関数のグラフ上に乗っているならば、

$$f(x_i) - y_i = 0 \quad (16)$$

を満たすべきであって、 $\varepsilon_i$  は、この左辺の値 (と 0 との誤差) である、とも言える。これと同様に考えると、

$$\varepsilon_i = (x_i - a)^2 + (y_i - b)^2 - r^2 \quad (17)$$

で同様の手続きをすればよいが、そのままでは上の式を二乗したときに  $a, b, r$  に関する四次式になってしまうので、最小値を求めることが難しい (偏微分がゼロの点が最小値とは限らない)。そこで、以下のように式変形を行う。

$$\begin{aligned} \varepsilon_i &= (x_i - a)^2 + (y_i - b)^2 - r^2 \\ &= x_i^2 - 2ax_i + a^2 + y_i^2 - 2by_i + b^2 - r^2 \\ &= -2ax_i - 2by_i + (a^2 + b^2 - r^2) + x_i^2 + y_i^2 \\ &= Ax_i + By_i + C + x_i^2 + y_i^2 \end{aligned} \quad (18)$$

ただし

$$\begin{aligned} A &= -2a, \\ B &= -2b, \\ C &= a^2 + b^2 - r^2 \end{aligned} \quad (19)$$

である。すると式 (3) は

$$\Delta := \frac{1}{2} \sum_{i=1}^N \varepsilon_i^2 = \frac{1}{2} \sum_{i=1}^N (Ax_i + By_i + C + x_i^2 + y_i^2)^2 \quad (20)$$

となって  $A, B, C$  の二次式となる。 $x_i, y_i$  は測定データで既知つまり定数であるから、これが四乗になっていても問題ないことに注意する。

これを  $A, B, C$  で偏微分すると

$$\begin{aligned}
\frac{\partial \Delta}{\partial A} &= \sum_{i=1}^N (Ax_i + By_i + C + x_i^2 + y_i^2) x_i = 0 \\
\frac{\partial \Delta}{\partial B} &= \sum_{i=1}^N (Ax_i + By_i + C + x_i^2 + y_i^2) y_i = 0 \\
\frac{\partial \Delta}{\partial C} &= \sum_{i=1}^N (Ax_i + By_i + C + x_i^2 + y_i^2) 1 = 0
\end{aligned} \tag{21}$$

従って

$$\begin{bmatrix} \sum_{i=1}^N x_i x_i, & \sum_{i=1}^N x_i y_i, & \sum_{i=1}^N x_i \\ \sum_{i=1}^N x_i y_i, & \sum_{i=1}^N y_i y_i, & \sum_{i=1}^N y_i \\ \sum_{i=1}^N x_i, & \sum_{i=1}^N y_i, & \sum_{i=1}^N 1 \end{bmatrix} \begin{bmatrix} A \\ B \\ C \end{bmatrix} = - \begin{bmatrix} \sum_{i=1}^N (x_i^2 + y_i^2) x_i \\ \sum_{i=1}^N (x_i^2 + y_i^2) y_i \\ \sum_{i=1}^N (x_i^2 + y_i^2) 1 \end{bmatrix} \tag{22}$$

後は、この連立方程式を解いて  $A, B, C$  を決定し、式 (19) に代入して

$$a = -\frac{A}{2}, \tag{23}$$

$$b = -\frac{B}{2}, \tag{24}$$

$$r = \sqrt{a^2 + b^2 - C} = \frac{\sqrt{A^2 + B^2 - 4C}}{2} \tag{25}$$

が得られる。

## 4.2 球の場合

球の場合は、変数が増えるだけで、円の場合と全く同じである。

中心  $(a, b, c)$  半径  $r$  の球の場合、点  $(x_i, y_i, z_i)$  がこの球の表面上にある時

$$(x_i - a)^2 + (y_i - b)^2 + (z_i - c)^2 - r^2 = 0 \tag{26}$$

を満たす筈である。よって誤差  $\varepsilon_i$  は

$$\begin{aligned}
\varepsilon_i &= (x_i - a)^2 + (y_i - b)^2 + (z_i - c)^2 - r^2 \\
&= x_i^2 - 2ax_i + a^2 + y_i^2 - 2by_i + b^2 + z_i^2 - 2cz_i + c^2 - r^2 \\
&= -2ax_i - 2by_i - 2cz_i + (a^2 + b^2 + c^2 - r^2) + x_i^2 + y_i^2 + z_i^2 \\
&= Ax_i + By_i + Cz_i + D + x_i^2 + y_i^2 + z_i^2
\end{aligned} \tag{27}$$

となる。ただし

$$\begin{aligned} A &= -2a, \\ B &= -2b, \\ C &= -2c, \\ D &= a^2 + b^2 + c^2 - r^2 \end{aligned} \quad (28)$$

である。すると式 (3) は

$$\Delta := \frac{1}{2} \sum_{i=1}^N \varepsilon_i^2 = \frac{1}{2} \sum_{i=1}^N (Ax_i + By_i + Cz_i + D + x_i^2 + y_i^2 + z_i^2)^2 \quad (29)$$

となって、これを  $A, B, C, D$  で偏微分すると

$$\begin{aligned} \frac{\partial \Delta}{\partial A} &= \sum_{i=1}^N (Ax_i + By_i + Cz_i + D + x_i^2 + y_i^2 + z_i^2) x_i = 0 \\ \frac{\partial \Delta}{\partial B} &= \sum_{i=1}^N (Ax_i + By_i + Cz_i + D + x_i^2 + y_i^2 + z_i^2) y_i = 0 \\ \frac{\partial \Delta}{\partial C} &= \sum_{i=1}^N (Ax_i + By_i + Cz_i + D + x_i^2 + y_i^2 + z_i^2) z_i = 0 \\ \frac{\partial \Delta}{\partial D} &= \sum_{i=1}^N (Ax_i + By_i + Cz_i + D + x_i^2 + y_i^2 + z_i^2) 1 = 0 \end{aligned} \quad (30)$$

従って

$$\begin{bmatrix} \sum_{i=1}^N x_i x_i, & \sum_{i=1}^N y_i x_i, & \sum_{i=1}^N z_i x_i, & \sum_{i=1}^N x_i \\ \sum_{i=1}^N x_i y_i, & \sum_{i=1}^N y_i y_i, & \sum_{i=1}^N z_i y_i, & \sum_{i=1}^N y_i \\ \sum_{i=1}^N x_i z_i, & \sum_{i=1}^N y_i z_i, & \sum_{i=1}^N z_i z_i, & \sum_{i=1}^N z_i \\ \sum_{i=1}^N x_i, & \sum_{i=1}^N y_i, & \sum_{i=1}^N z_i, & \sum_{i=1}^N 1 \end{bmatrix} \begin{bmatrix} A \\ B \\ C \\ D \end{bmatrix} = - \begin{bmatrix} \sum_{i=1}^N (x_i^2 + y_i^2 + z_i^2) x_i \\ \sum_{i=1}^N (x_i^2 + y_i^2 + z_i^2) y_i \\ \sum_{i=1}^N (x_i^2 + y_i^2 + z_i^2) z_i \\ \sum_{i=1}^N (x_i^2 + y_i^2 + z_i^2) 1 \end{bmatrix} \quad (31)$$

後は、この連立方程式を解いて  $A, B, C, D$  を決定し、式 (28) に代入して

$$a = -\frac{A}{2}, \quad (32)$$

$$b = -\frac{B}{2}, \quad (33)$$

$$c = -\frac{C}{2}, \quad (34)$$

$$r = \sqrt{a^2 + b^2 + c^2 - D} = \frac{\sqrt{A^2 + B^2 + C^2 - 4D}}{2} \quad (35)$$

が得られる。

## 5 (応用) 疑似逆行列

行列  $A$  が正方行列であって、逆行列  $A^{-1}$  が存在する時、連立方程式  $A\mathbf{x} = \mathbf{b}$  は、 $\mathbf{x} = A^{-1}\mathbf{b}$  と解くことができる。

ここでは  $A$  が正方行列でない場合を考える。今回は、行の方が多つまり  $A$  が  $m \times n$  行列の時に  $m > n$  である場合だけ考えよう。この場合、連立方程式で言うならば、変数の数  $n$  よりも式の数  $m$  の方が多いのだから、一般には解が存在しない。そこで、近似解を求めることで妥協する。

まず、連立方程式の右辺を移項して、右辺をゼロに変形しておく。

$$A\mathbf{x} - \mathbf{b} = \mathbf{0} \quad (36)$$

このような  $x$  は存在しないから、先ほどまでの最小二乗法と同じ考えで、誤差に相当する

$$\|A\mathbf{x} - \mathbf{b}\| \quad (37)$$

が最小になるように  $\mathbf{x}$  を求めることにする。

$m \times n$  行列  $A$  に対して、以下の 4 条件を満たす  $n \times m$  行列  $A^+$  がただ一つ定まる：

$$AA^+A = A, \quad (38)$$

$$A^+AA^+ = A^+ \quad (39)$$

$$(AA^+)^* = AA^+ \quad (40)$$

$$(A^+A)^* = A^+A \quad (41)$$

なお、 $A^*$  は  $A$  の随伴行列 (各要素の複素共役を取りさらに転置した行列) を表す。

この行列  $A^+$  を  $A$  の疑似逆行列と呼ぶ。 $A$  が正則でなくても  $A^+$  は定まる。 $A$  が正則ならば  $A$  の逆行列はこの性質を満たす (つまり  $A^+ = A^{-1}$ )。



詳しくは省略するが  $A$  の各列が線形独立であれば、 $A^*A$  は可逆であり、

$$A^+ = (A^*A)^{-1} A^* \quad (42)$$

が成り立つ。この時 存在しない  $A^{-1}$  の代わりに  $A^+$  を用いることで

$$\boldsymbol{x} = A^+ \boldsymbol{b} \quad (43)$$

とすれば、この  $\boldsymbol{x}$  は 式 (37) を最小にするベクトルである。